

**Московский государственный технический
университет им. Н.Э. Баумана.**

Факультет «Информатика и управление»

Кафедра «Системы обработки информации и управления»

Курс «Теория машинного обучения»

Отчет по лабораторной работе №5

Выполнил:
студент группы ИУ5-64
Кузьмин Роман

Подпись и дата:

Проверил:
преподаватель каф. ИУ5
Гапанюк Ю.Е.

Подпись и дата:

Москва, 2022 г.

Описание задания

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода `train_test_split` разделите выборку на обучающую и тестовую.
4. Обучите следующие ансамблевые модели:
 - одну из моделей группы бэггинга (бэггинг или случайный лес или сверхслучайные деревья);
 - одну из моделей группы бустинга;
 - одну из моделей группы стекинга.
5. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

Текст программы и её результаты

```
from sklearn.datasets import fetch_covtype
import pandas as pd
from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier
from sklearn.ensemble import StackingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
import numpy as np
import matplotlib.pyplot as plt
import warnings
%matplotlib inline

data = fetch_covtype(as_frame=True)['data']
data["type"] = fetch_covtype(as_frame=True)['target']
data.head()
```

	Elevation	Aspect	Slope	Horizontal_Distance_To_Hydrology	Vertical_Distance_To_Hydrology	Horizontal_Distance_To_Hydrology
0	2596.0	51.0	3.0	258.0	0.0	
1	2590.0	56.0	2.0	212.0	-6.0	
2	2804.0	139.0	9.0	268.0	65.0	
3	2785.0	155.0	18.0	242.0	118.0	
4	2595.0	45.0	2.0	153.0	-1.0	

5 rows x 55 columns

Пропусков нет

data.isna().sum()

Elevation	0
Aspect	0
Slope	0
Horizontal_Distance_To_Hydrology	0
Vertical_Distance_To_Hydrology	0
Horizontal_Distance_To_Roadways	0
Hillshade_9am	0
Hillshade_Noon	0
Hillshade_3pm	0
Horizontal_Distance_To_Fire_Points	0
Wilderness_Area_0	0
Wilderness_Area_1	0
Wilderness_Area_2	0
Wilderness_Area_3	0
Soil_Type_0	0
Soil_Type_1	0
Soil_Type_2	0
Soil_Type_3	0
Soil_Type_4	0
Soil_Type_5	0
Soil_Type_6	0
Soil_Type_7	0
Soil_Type_8	0
Soil_Type_9	0
Soil_Type_10	0
Soil_Type_11	0
Soil_Type_12	0
Soil_Type_13	0
Soil_Type_14	0
Soil_Type_15	0
Soil_Type_16	0
Soil_Type_17	0
Soil_Type_18	0

```
[ ] X_train, X_test, y_train, y_test = train_test_split(data.drop('type', axis=1), data['type'], test_size=0.3, random_state=42)
```

```
[ ] tree1 = RandomForestClassifier(n_estimators=5, oob_score=True, random_state=10)
tree1.fit(X_train, y_train)
pred1 = tree1.predict(X_test)
accuracy_score(y_test, pred1)
```

0.9253660271709198

```
[ ] boost1 = AdaBoostClassifier(n_estimators=5, algorithm='SAMME', random_state=10)
boost1.fit(X_train, y_train)
pred2 = boost1.predict(X_test)
accuracy_score(y_test, pred2)
```

0.633565494767762

```
➤ classifier = StackingClassifier(
    [
        ('lr', LogisticRegression()),
        ('dt', DecisionTreeClassifier())
    ],
    LogisticRegression()
)
classifier.fit(X_train, y_train)
```

```
[ ] classifier = StackingClassifier(  
    [  
        ('lr', LogisticRegression()),  
        ('dt', DecisionTreeClassifier())  
    ],  
    LogisticRegression()  
)  
classifier.fit(X_train, y_train)  
  
StackingClassifier(estimators=[('lr', LogisticRegression()),  
                               ('dt', DecisionTreeClassifier())],  
                   final_estimator=LogisticRegression())  
  
[ ] pred3 = classifier.predict(X_test)  
accuracy_score(y_test, pred3)  
  
0.9339372590416744
```